

Смеси экспертов

Грабовой Андрей Валериевич

Московский физико-технический институт

МФТИ, г. Долгопрудный

① ЕМ–алгоритм:

- Классический,
- Вариационный,

② Смесь моделей:

- Постановка задачи,
- Итерационные формулы полученные при помощи вариационного ЕМ–алгоритма,
- Иллюстрация сходимости,

③ Смесь экспертов

- Постановка задачи,
- Итерационные формулы полученные при помощи вариационного ЕМ–алгоритма,
- Иллюстрация сходимости,

Максимизация обоснованности:

$$\Theta = \arg \max_{\Theta} p(\mathbf{y}|\mathbf{X}, \Theta) \quad (1)$$

ELBO:

$$\begin{aligned} \mathcal{L}(q(\mathbf{Z}), \Theta) &= \int q(\mathbf{Z}) \log \frac{p(\mathbf{y}, \mathbf{Z}|\Theta, \mathbf{X})}{q(\mathbf{Z})} d\mathbf{Z} \\ &= p(\mathbf{y}|\mathbf{X}, \Theta) - D_{KL}(q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{y}, \mathbf{X}, \Theta)) \end{aligned} \quad (2)$$

EM-алгоритм:

❶ E-шаг:

$$q^s(\mathbf{Z}) = \arg \max_{q(\mathbf{Z}) \in Q} \mathcal{L}(q(\mathbf{Z}), \Theta^{s-1}) \quad (3)$$

❷ M-шаг:

$$\Theta^s = \arg \max_{\Theta} \mathcal{L}(q^s(\mathbf{Z}), \Theta) \quad (4)$$

Вариационный EM-алгоритм (Mean Field Approximation¹):

❶ E-шаг:

$$\log q(\mathbf{Z}_k^s) \propto \mathbb{E}_{q/k} \log p(\mathbf{y}, \mathbf{Z}|\mathbf{X}, \Theta^{s-1}) \quad (5)$$

❷ M-шаг:

$$\Theta^s = \arg \max_{\Theta} \mathbb{E}_{q^s} \log p(\mathbf{y}, \mathbf{Z}|\mathbf{X}, \Theta) \quad (6)$$

¹<https://github.com/andriygav/EMprior/blob/master/Lecture/Grabovoy2019MeanField.pdf>

Definition

Смесь моделей — мультимодель, ответы которой представляют собой взвешенную сумму ответов всех задействованных моделей независимо от объекта.

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k = \text{const}, \quad \sum_{k=1}^K \pi_k = 1, \quad (7)$$

где \mathbf{f} — мультимодель, а \mathbf{f}_k — локальная модель.

Пример 1:

- ❶ Веса моделей в смеси $\boldsymbol{\pi}$ получены из априорного распределения

$$p(\boldsymbol{\pi}|\mu); \quad (8)$$

- ❷ Вектора параметров \mathbf{w}_k получены из нормального распределения

$$p(\mathbf{w}_k|\mathbf{A}_k) = \mathcal{N}(\mathbf{w}_k|\mathbf{0}, \mathbf{A}_k), \quad k = 1, \dots, K; \quad (9)$$

- ❸ Для каждого объекта \mathbf{x}_i существует модель \mathbf{f}_{k_i} , которой он описывается, причем $p(k_i = k) = \pi_k$;

- ❹ Для каждого объекта \mathbf{x}_i класс y_i определен в соответствии с моделью

$$\mathbf{f}_{k_i} : y_i \sim \mathcal{N}(\mathbf{w}_{k_i}^\top \mathbf{x}_i + b_k, \beta^{-1}) \quad (10)$$

Правдоподобие модели:

$$p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi} | \mathbf{X}, \mathbf{A}, \beta, \boldsymbol{\mu}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu}) \prod_{k=1}^K N(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \left(\sum_{k=1}^K \pi_k \mathcal{N}(y_i | \mathbf{w}_k^T \mathbf{x}_i, \beta^{-1}) \right) \quad (11)$$

Введем скрытые переменные $\mathbf{Z} = ||z_{ik}||$, где $z_{ik} = 1 \Leftrightarrow k_i = k$:

$$p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \beta, \boldsymbol{\mu}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu}) \prod_{k=1}^K N(\mathbf{w}_k | \mathbf{0}, \mathbf{A}_k) \prod_{i=1}^N \prod_{k=1}^K \left(\pi_k \mathcal{N}(y_i | \mathbf{w}_k^T \mathbf{x}_i, \beta^{-1}) \right)^{z_{ik}} \quad (12)$$

Вариационный EM-алгоритм $q(\mathbf{Z}, \mathbf{W}, \boldsymbol{\pi}) = q(\mathbf{Z}) q(\mathbf{W}) q(\boldsymbol{\pi})$:

① E-шаг:

$$\begin{aligned} \log q(\mathbf{Z}^s) &\propto \mathbb{E}_{q/\mathbf{Z}} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}^{s-1}, \beta^{s-1}, \boldsymbol{\mu}) \\ \log q(\mathbf{W}^s) &\propto \mathbb{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}^{s-1}, \beta^{s-1}, \boldsymbol{\mu}) \\ \log q(\boldsymbol{\pi}^s) &\propto \mathbb{E}_{q/\boldsymbol{\pi}} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}^{s-1}, \beta^{s-1}, \boldsymbol{\mu}) \end{aligned} \quad (13)$$

② M-шаг:

$$\mathbf{A}^s, \beta^s = \arg \max_{\mathbf{A}, \beta} \mathbb{E}_{q^s} \log p(\mathbf{y}, \mathbf{W}, \boldsymbol{\pi}, \mathbf{Z} | \mathbf{X}, \mathbf{A}, \beta, \boldsymbol{\mu}) \quad (14)$$

Итерационные формулы EM-алгоритма¹:

❶ E-шаг:

$$p(z_{ik} = 1) = \frac{\exp \left(\mathbb{E} \log \pi_k - \frac{\beta}{2} \left[y_i^2 - 2y_i \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top (\mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top) \mathbf{x}_i \right] \right)}{\sum_k p(z_{ik} = 1)},$$

$$q(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\mu} + \boldsymbol{\gamma}), \quad q(\mathbf{w}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{m}_k, \mathbf{B}_k),$$

$$\gamma_k = \sum_{i=1}^N \mathbb{E} z_{ik}, \quad \mathbf{m}_k = \beta \mathbf{B}_k \left(\sum_{i=1}^N \mathbf{x}_i y_i \mathbb{E} z_{ik} \right), \quad \mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbb{E} z_{ik} \right)^{-1}. \quad (15)$$

❷ M-шаг:

$$\begin{aligned} \mathbf{A}_k &= \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \\ \frac{1}{\beta} &= \frac{\sum \sum [y_i^2 - 2y_i \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i] \mathbb{E} z_{ik}}{\sum \sum \mathbb{E} z_{ik}} \end{aligned} \quad (16)$$

Некоторые математические ожидания:


❶ $\mathbb{E} z_{ik} = p(z_{ik} = 1),$

❷ $\mathbb{E} \log \pi_k = \psi^0(\mu_k + \gamma_k) - \psi^0(K\mu_k + N),$


❸ $\mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top = \mathbf{B}_k + \mathbf{m}_k \mathbf{m}_k^\top.$

¹<https://github.com/andriygav/EMprior/blob/master/paper/Grabovoy2019Draft.pdf>

Пример 1



(a)



(b)

На рис. 1a показано, что в случае смеси моделей, предсказать то, какую модель использовать в каждой точке нельзя.

На рис. 1b показана зависимость векторов \mathbf{w}_k — параметры локальных моделей в процессе обучения.

¹<https://github.com/andriygav/MixtureLib>

Definition

Смесь экспертов — мультимодель, определяющая правдоподобие веса π_k каждой локальной модели \mathbf{f}_k на признаковом описании объекта \mathbf{x} .

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k(\mathbf{x}, \mathbf{V}) : \mathbb{R}^{n \times |\mathbf{V}|} \rightarrow [0, 1], \quad \sum_{k=1}^K \pi_k(\mathbf{x}, \mathbf{V}) = 1 \quad (17)$$

где $\hat{\mathbf{f}}$ — мультимодель, а \mathbf{f}_k является некоторой моделью,
 π_k — параметрическая модель, \mathbf{w}_k — параметры k -й локальной модели,
 \mathbf{V} — параметры шлюзовой функции.

Пример 2:

- ❶ Правдоподобие k -й локальной модели $p_k(y_i | \mathbf{w}_k, \mathbf{x}_i) = \mathcal{N}(y_i | \mathbf{w}_k^T \mathbf{x}_i, \beta^{-1})$,
- ❷ Априорное распределение параметров k -й локальной модели $p^k(\mathbf{w}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{w}_k^0, \mathbf{A}_k)$,
- ❸ Шлюзовая функция $\pi(\mathbf{x}, \mathbf{V}) = \text{softmax}(\mathbf{V}_1^T \boldsymbol{\sigma}(\mathbf{V}_2^T \mathbf{x}))$.

Правдоподобие модели:

$$p(\mathbf{y}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \beta) = \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k | \mathbf{w}_k^0, \mathbf{A}_k) \prod_{i=1}^N \left(\sum_{k=1}^K \pi_k \mathcal{N}(y_i | \mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1}) \right). \quad (18)$$

Введем скрытые переменные $\mathbf{Z} = ||z_{ik}||$, где $z_{ik} = 1 \Leftrightarrow k_i = k$:

$$p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \beta) = \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k | \mathbf{w}_k^0, \mathbf{A}_k) \prod_{i=1}^N \prod_{k=1}^K \left(\pi_k \mathcal{N}(y_i | \mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1}) \right)^{z_{ik}}. \quad (19)$$

Вариационный EM-алгоритм $q(\mathbf{Z}, \mathbf{W}) = q(\mathbf{Z}) q(\mathbf{W})$:

① E-шаг:

$$\begin{aligned} \log q(\mathbf{Z}^s) &\propto \mathbf{E}_{q/\mathbf{Z}} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}^{s-1}, \mathbf{A}^{s-1}, \mathbf{W}^{0,s-1}, \beta^{s-1}) \\ \log q(\mathbf{W}^s) &\propto \mathbf{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}^{s-1}, \mathbf{A}^{s-1}, \mathbf{W}^{0,s-1}, \beta^{s-1}) \end{aligned} \quad (20)$$

② M-шаг:

$$\mathbf{W}^{0,s}, \mathbf{A}^s, \beta^s = \arg \max_{\mathbf{W}^0, \mathbf{A}, \beta} \mathbf{E}_{q^s} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \beta) \quad (21)$$

Итерационные формулы EM-алгоритма¹:

① E-шаг:

$$p(z_{ik} = 1) = \frac{\exp(\log \pi_k(\mathbf{x}_i, \mathbf{V}) - \frac{\beta}{2} (\mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i - \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k))}{\sum_{k'=1}^K \exp(\log \pi_{k'}(\mathbf{x}_i, \mathbf{V}) - \frac{\beta}{2} (\mathbf{x}_i^\top \mathbf{E} \mathbf{w}_{k'} \mathbf{w}_{k'}^\top \mathbf{x}_i - \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_{k'}))},$$

$$q(\mathbf{w}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{m}_k, \mathbf{B}_k),$$

$$\mathbf{m}_k = \mathbf{B}_k \left(\mathbf{A}_k^{-1} \mathbf{w}_k^0 + \beta \sum_{i=1}^N \mathbf{x}_i y_i \mathbf{E} z_{ik} \right), \quad \mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbf{E} z_{ik} \right)^{-1}.$$
(22)

② M-шаг:


$$\mathbf{A}_k = \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top - \mathbf{w}_k^0 \mathbf{E} \mathbf{w}_k^\top - \mathbf{E} \mathbf{w}_k \mathbf{w}_k^{0\top} + \mathbf{w}_k^0 \mathbf{w}_k^{0\top},$$

$$\frac{1}{\beta} = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \left[y_i^2 - 2 y_i \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i \right] \mathbf{E} z_{ik},$$
(23)


$$\mathbf{w}_k^0 = \mathbf{E} \mathbf{w}_k,$$

$$\mathbf{V} = \arg \max_{\mathbf{V}} \mathbf{E}_{q^s} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \beta).$$

¹<https://github.com/andriygav/EMprior/blob/master/paper/Grabovoy2019MixtureOfExpert.pdf>



(c)




(d)


На рис. 1с показано, что в случае смеси экспертов гипермодель предсказывает к какому классу относится каждая точка в пространстве объектов.

На рис. 1d показана зависимость векторов \mathbf{w}_k — параметры локальных моделей в процессе обучения.


¹<https://github.com/andriygav/MixtureLib>




(е) Смесь Моделей



(f) Смесь Моделей



(g) Смесь Экспертов



(h) Смесь Экспертов

¹<https://github.com/andriygav/MixtureLib>

Цель: предложить метод построения ансамбля локально аппроксимирующих моделей для поиска окружностей на изображении.

Задачи

- 1 Предложить метод поиска окружности при помощи линейной модели, для поиска нескольких окружностей предложить метод построения смеси локальных аппроксимирующих моделей.
- 2 Предложить априорные распределения на параметры локальных моделей.

Исследуемая проблема

- 1 Снижение размерности пространства описаний изображения.

Метод решения

В качестве мультимодели предлагается использовать смесь экспертов. Для повышения качества мультимодели предлагается ввести априорные распределения параметров локальных моделей. Вводится *регуляризация* априорных распределений для учета взаимосвязи между априорными распределениями разных локальных моделей смеси.

- ❶ *Yuksel Seniha Esen, Wilson Joseph N., Gader Paul D* Twenty Years of Mixture of Experts // IEEE Transactions on Neural Networks and Learning Systems. 2012. Issues. 23, No 8. pp. 1177–1193.
- ❷ *A. P. Dempster, N. M. Laird and D. B. Rubin* Maximum Likelihood from Incomplete Data via the EM Algorithm // Journal of the Royal Statistical Society. Series B (Methodological), Vol. 39, No. 1 pp. 1-38, 1977.
- ❸ *Bishop C.* Pattern Recognition and Machine Learning. — Berlin: Springer, 2006. 758 p.
- ❹ *I. Matveev* Detection of iris in image by interrelated maxima of brightness gradient projections // Appl.Comput. Math. 9 (2), 252–257, 2010.
- ❺ *K. Bowyer, K. Hollingsworth, P. Flynn* A Survey of Iris Biometrics Research: 2008–2010.

Постановка задачи нахождения параметров окружностей

Задано бинарное изображение:

$$\mathbf{M} \in \{0, 1\}^{m_1 \times m_2},$$

где 1 — черная точка, 0 — белая точка фона.

По изображению \mathbf{M} строится выборка \mathbf{C} :

$$\mathbf{C} \in \mathbb{R}^{N \times 2},$$

где N — число черных точек на изображении \mathbf{M} .

Пусть x_0, y_0 — центр окружности, которую требуется найти, а r ее радиус.

Точки $(x_i, y_i) \in \mathbf{C}$ должны удовлетворять уравнению окружности:


$$(x_i - x_0)^2 + (y_i - y_0)^2 = r^2 \Rightarrow (2x_0) \cdot x_i + (2y_0) \cdot y_i + (r^2 - x_0^2 - y_0^2) \cdot 1 = x_i^2 + y_i^2.$$

Задачу линейной регрессии для нахождения окружности:

$$\mathbf{X}\mathbf{w} \approx \mathbf{y}, \quad \mathbf{X} = [\mathbf{C}, \mathbf{1}], \quad \mathbf{y} = [x_1^2 + y_1^2, x_2^2 + y_2^2, \dots, x_N^2 + y_N^2]^\top,$$

где найденные оптимальные параметры линейной регрессии $\mathbf{w} = [w_1, w_2, w_3]^\top$ восстанавливают параметры окружности:

$$x_0 = \frac{w_1}{2}, \quad y_0 = \frac{w_2}{2}, \quad r = \sqrt{w_3 + x_0^2 + y_0^2}.$$



Задана выборка:

$$\mathbf{X} \in \mathbb{R}^{N \times n},$$

где N — число объектов в выборке, а n — размерность признакового пространства.

Definition

Смесь экспертов — мультимодель, определяющая правдоподобие веса π_k каждой локальной модели \mathbf{f}_k на признаковом описании объекта \mathbf{x} .

$$\hat{\mathbf{f}} = \sum_{k=1}^K \pi_k \mathbf{f}_k, \quad \pi_k(\mathbf{x}, \mathbf{V}) : \mathbb{R}^{n \times |\mathbf{V}|} \rightarrow [0, 1], \quad \sum_{k=1}^K \pi_k(\mathbf{x}, \mathbf{V}) = 1,$$

где $\hat{\mathbf{f}}$ — мультимодель, а \mathbf{f}_k является локальной моделью, π_k — шлюзовая функция, \mathbf{w}_k — параметры k -й локальной модели, \mathbf{V} — параметры шлюзовой функции.

В качестве локальных моделей \mathbf{f}_k и шлюзовой функции π рассматриваются следующие функции:

$$\mathbf{f}_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x}, \quad \pi(\mathbf{x}, \mathbf{V}) = \text{softmax}(\mathbf{V}_1^T \boldsymbol{\sigma}(\mathbf{V}_2^T \mathbf{x})),$$

где $\mathbf{V} = \{\mathbf{V}_1, \mathbf{V}_2\}$ — параметры шлюзовой функции.

Параметры локальных моделей оптимизируются согласно принципу максимального правдоподобия модели:

$$p(\mathbf{y}, \mathbf{W} | \mathbf{X}, \mathbf{V}) = \prod_{k=1}^K p^k(\mathbf{w}_k) \prod_{i=1}^N \left(\sum_{k=1}^K \pi_k p_k(y_i | \mathbf{w}_k, \mathbf{x}_i) \right),$$

где $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_K]^T$.

Задача оптимизации параметров локальных моделей и параметров смеси:

$$\hat{\mathbf{W}}, \hat{\mathbf{V}} = \arg \max_{\mathbf{W}, \mathbf{V}} p(\mathbf{y}, \mathbf{W} | \mathbf{X}, \mathbf{V}).$$

Рассматривается вероятностная постановка задачи:

- 1) правдоподобие выборки $p_k(y_i | \mathbf{w}_k, \mathbf{x}_i) = \mathcal{N}(y_i | \mathbf{w}_k^T \mathbf{x}_i, \beta^{-1})$, где β уровень шума,
- 2) априорное распределение параметров $p^k(\mathbf{w}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{w}_k^0, \mathbf{A}_k)$, где \mathbf{w}_k^0 — вектор размера $n \times 1$, \mathbf{A}_k — ковариационная матрица параметров,
- 3) регуляризация априорного распределения $p(\boldsymbol{\varepsilon}_{k,k'} | \boldsymbol{\alpha}) = \mathcal{N}(\boldsymbol{\varepsilon}_{k,k'} | \mathbf{0}, \boldsymbol{\Xi})$, где $\boldsymbol{\Xi}$ — ковариационная матрица общего вида, $\boldsymbol{\varepsilon}_{k,k'} = \mathbf{w}_k^0 - \mathbf{w}_{k'}^0$.

Правдоподобие модели включает правдоподобие выборки, априорное распределение параметров, а также их регуляризацию

$$p(\mathbf{y}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \mathbf{\Xi}, \beta) = \prod_{k, k'=1}^K \mathcal{N}(\boldsymbol{\varepsilon}_{k, k'} | \mathbf{0}, \mathbf{\Xi}) \cdot \prod_{k=1}^K \mathcal{N}(\mathbf{w}_k | \mathbf{w}_k^0, \mathbf{A}_k) \prod_{i=1}^N \left(\sum_{k=1}^K \pi_k \mathcal{N}(y_i | \mathbf{w}_k^\top \mathbf{x}_i, \beta^{-1}) \right),$$

где $\mathbf{A} = \{\mathbf{A}_1, \dots, \mathbf{A}_K\}$. Введем скрытые переменные $\mathbf{Z} = [z_{ik}]$, где $z_{ik} = 1$ тогда и только тогда, когда $k_i = k$:

$$\begin{aligned} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \mathbf{\Xi}, \beta) = & \sum_{i=1}^N \sum_{k=1}^K z_{ik} \left[\log \pi_k(\mathbf{x}_i, \mathbf{V}) - \frac{\beta}{2} \left(y_i - \mathbf{w}_k^\top \mathbf{x}_i \right)^2 + \frac{1}{2} \log \frac{\beta}{2\pi} \right] + \\ & + \sum_{k=1}^K \left[-\frac{1}{2} (\mathbf{w}_k - \mathbf{w}_k^0)^\top \mathbf{A}_k^{-1} (\mathbf{w}_k - \mathbf{w}_k^0) + \frac{1}{2} \log \det \mathbf{A}_k^{-1} - \frac{n}{2} \log 2\pi \right] + \\ & + \sum_{k=1}^K \sum_{k'=1}^K \left[-\frac{1}{2} (\mathbf{w}_k^0 - \mathbf{w}_{k'}^0)^\top \hat{\boldsymbol{\alpha}}^{-1} (\mathbf{w}_k^0 - \mathbf{w}_{k'}^0) + \frac{1}{2} \log \det \mathbf{\Xi} - \frac{n}{2} \log 2\pi \right]. \end{aligned}$$

Задача оптимизации параметров локальных моделей и параметров смеси принимает следующий вид:

$$\mathbf{W}, \mathbf{Z}, \mathbf{V}, \mathbf{W}^0, \mathbf{A}, \beta = \arg \max_{\mathbf{W}, \mathbf{Z}, \mathbf{V}, \mathbf{W}^0, \mathbf{A}, \beta} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \Xi, \beta).$$

Для оптимизации используется вариационный ЕМ–алгоритм с аппроксимацией среднего поля $q(\mathbf{Z}, \mathbf{W}) = q(\mathbf{Z}) q(\mathbf{W})$.

Е и М шаги алгоритма имеют следующий вид:

① Е–шаг:

$$\begin{aligned} \log q(\mathbf{Z}^s) &\propto \mathbb{E}_{q/\mathbf{Z}} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}^{s-1}, \mathbf{A}^{s-1}, \mathbf{W}^{0,s-1}, \Xi, \beta^{s-1}), \\ \log q(\mathbf{W}^s) &\propto \mathbb{E}_{q/\mathbf{W}} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}^{s-1}, \mathbf{A}^{s-1}, \mathbf{W}^{0,s-1}, \Xi, \beta^{s-1}), \end{aligned}$$

② М–шаг:

$$\mathbf{W}^{0,s}, \mathbf{A}^s, \mathbf{V}^s, \beta^s = \arg \max_{\mathbf{W}^0, \mathbf{A}, \mathbf{V}, \beta} \mathbb{E}_{q^s} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \Xi, \beta),$$

где s — номер итерации.

Итерационные формулы ЕМ–алгоритма:

① Е–шаг:

$$p(z_{ik} = 1) = \frac{\exp(\log \pi_k(\mathbf{x}_i, \mathbf{V}) - \frac{\beta}{2}(\mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i - \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k))}{\sum_{k'=1}^K \exp(\log \pi_{k'}(\mathbf{x}_i, \mathbf{V}) - \frac{\beta}{2}(\mathbf{x}_i^\top \mathbf{E} \mathbf{w}_{k'} \mathbf{w}_{k'}^\top \mathbf{x}_i - \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_{k'}))},$$

$$q(\mathbf{w}_k) = \mathcal{N}(\mathbf{w}_k | \mathbf{m}_k, \mathbf{B}_k),$$

$$\mathbf{m}_k = \mathbf{B}_k \left(\mathbf{A}_k^{-1} \mathbf{w}_k^0 + \beta \sum_{i=1}^N \mathbf{x}_i y_i \mathbf{E} z_{ik} \right), \quad \mathbf{B}_k = \left(\mathbf{A}_k^{-1} + \beta \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \mathbf{E} z_{ik} \right)^{-1}.$$

② М–шаг:

$$\mathbf{A}_k = \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top - \mathbf{w}_k^0 \mathbf{E} \mathbf{w}_k^\top - \mathbf{E} \mathbf{w}_k \mathbf{w}_k^{0\top} + \mathbf{w}_k^0 \mathbf{w}_k^{0\top},$$

$$\frac{1}{\beta} = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \left[y_i^2 - 2y_i \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k + \mathbf{x}_i^\top \mathbf{E} \mathbf{w}_k \mathbf{w}_k^\top \mathbf{x}_i \right] \mathbf{E} z_{ik},$$

$$\mathbf{w}_k^0 = [\mathbf{A}_k^{-1} + (K-1) \mathbf{\Xi}]^{-1} \left(\mathbf{A}_k^{-1} \mathbf{E} \mathbf{w}_k + \mathbf{\Xi} \sum_{k'=1, k' \neq k}^K \mathbf{w}_{k'}^0 \right),$$

$$\mathbf{V} = \arg \max_{\mathbf{V}} \mathbf{E}_{q^s} \log p(\mathbf{y}, \mathbf{Z}, \mathbf{W} | \mathbf{X}, \mathbf{V}, \mathbf{A}, \mathbf{W}^0, \mathbf{\Xi}, \beta).$$

Вычислительный эксперимент делится на следующие этапы:

- 1 Анализ синтетических данных с разным типом шума в изображении;
- 2 Анализ изменения параметров локальных моделей во время обучения;
- 3 Анализ мультимodelей в зависимости от уровня шума в изображении;
- 4 Анализ качества модели на реальных данные.

Гиперпараметры заданы следующим образом:

- 1 Априорные распределения на параметры локальных моделей в эксперименте задано следующим образом:

$$p^1(\mathbf{w}_1) \sim \mathcal{N}(\mathbf{w}_1^0, \mathbf{I}), \quad p^2(\mathbf{w}_2) \sim \mathcal{N}(\mathbf{w}_2^0, \mathbf{I}),$$

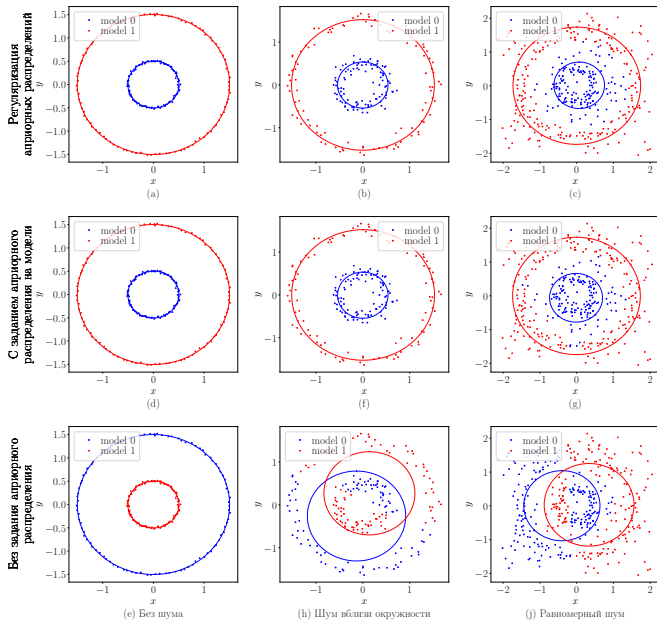
где $\mathbf{w}_1^0 = [0, 0, 0.1]$, $\mathbf{w}_2^0 = [0, 0, 2]$.

- 2 Параметр регуляризации:

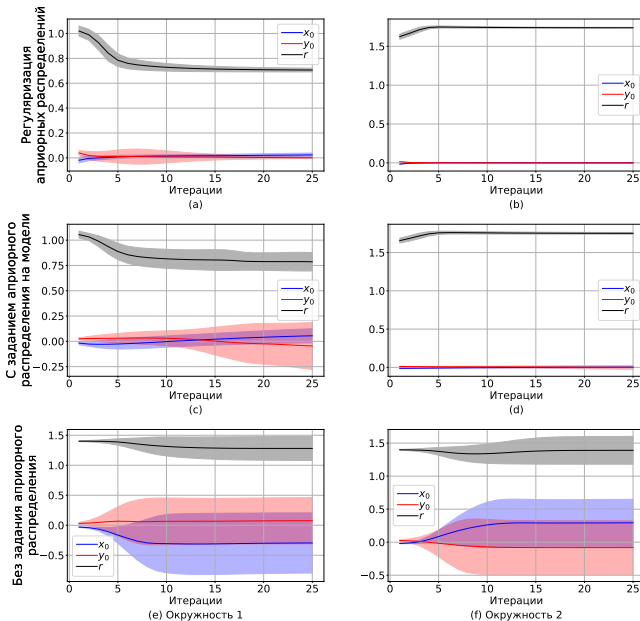
$$\Xi = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

что указывает на концентричность окружностей.


Синтетические данные с разным типом шума в изображении




Параметры локальных моделей в процессе обучения




Регуляризация априорных распределений









С заданием априорного распределения на модели

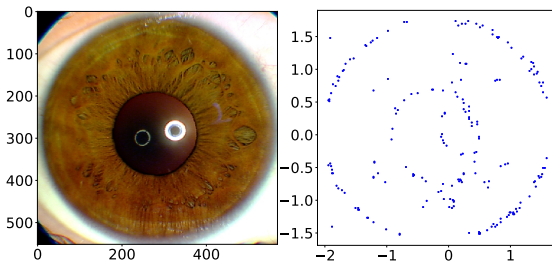


Без задания априорного распределения




Анализ мультимоделей в зависимости от уровня шума





(a) Исходное изображение

(b) Бинаризованное изображение




(c) Без задания априорного распределения


(d) С заданием априорного распределения на модели

(e) Регуляризация априорных распределений


Регуляризация априорных распределений



С заданием априорного распределения на модели



Без задания априорного распределения



Сделано:

- 1 Предложен метод поиска окружностей на бинарном изображении с различными априорными предположениями.
- 2 Введено понятие регуляризации априорных распределений для улучшения качества мультимодели.
- 3 В эксперименте показано, что задания регуляризации позволяет улучшить качество и устойчивость модели.

Планируется:

- 1 Улучшить мультимодель при помощи задания априорного распределения на шлюзовую функцию.
- 2 Рассмотреть в качестве локальных моделей не только модели, которые описывают данные, а также модель, которая отвечает за шум в данных.
- 3 Расширить класс локальных моделей с окружности до произвольной кривой второго порядка.

Пусть задано множество объектов Ω , а также подмножество наблюдаемых объектов Ω'

$$\Omega' \subset \Omega,$$

где $|\Omega'| = N$. Пусть для Ω задана некоторая экспертная информация $E(\Omega)$. На основе экспертной информации $E(\Omega)$ введем отображения из множества объектов Ω :

$$K_y^{E(\Omega)} : \Omega \rightarrow \mathbb{R}, \quad K_x^{E(\Omega)} : \Omega \rightarrow \mathbb{R}^n,$$

где n количество признаков, причем предполагаем, что $n \ll N$. Применив отображения $K_x^{E(\Omega)}$ и $K_y^{E(\Omega)}$ для множества наблюдаемых объектов Ω' получаем выборку:

$$\mathfrak{D}(\Omega', E(\Omega)) = \{(\mathbf{x}, y) \mid \mathbf{x} = K_x^{E(\Omega)}(\omega), y = K_y^{E(\Omega)}(\omega), \forall \omega \in \Omega'\}.$$

Предполагается, что существуют нетривиальные отображения $K_y^{E(\Omega)}, K_x^{E(\Omega)}$, и $\mathbf{w} \in \mathbb{R}^n$, такие, что:

$$y \approx \mathbf{x}^\top \mathbf{w}, \quad \forall (\mathbf{x}, y) \in \mathfrak{D}(\Omega', E(\Omega)),$$

то есть получаем выборку, которая является задачей линейной регрессии по нахождению неизвестного вектора \mathbf{w} (аналогично можно ввести задачу для логистической регрессии).

В случае, когда экспертная информация представляется в виде объединения нескольких экспертов:

$$\mathbf{E}(\Omega) = \mathbf{E}_0(\Omega) \cup \mathbf{E}_1(\Omega_1) \cup \mathbf{E}_2(\Omega_2) \cup \dots \cup \mathbf{E}_K(\Omega_K), \quad \bigcup_{i=1}^K \Omega_i = \Omega$$

в этом случае будем говорить о задаче смеси K экспертов. Каждая информация $\mathbf{E}_k(\Omega_k)$ описывает локальную информацию о каком-то подмножестве объектов Ω_k для всех $k = \overline{1 \dots K}$. Информация эксперта $\mathbf{E}_0(\Omega)$ описывает глобальную информацию о всем множестве объектов Ω .

В случае задачи смеси K экспертов вводятся отображения:

$$\begin{aligned} K_y^{\mathbf{E}_1(\Omega_1)} : \Omega \rightarrow \mathbb{R}, \quad K_x^{\mathbf{E}_1(\Omega_1)} : \Omega \rightarrow \mathbb{R}^{n_1}, \\ \dots \\ K_y^{\mathbf{E}_K(\Omega_K)} : \Omega \rightarrow \mathbb{R}, \quad K_x^{\mathbf{E}_K(\Omega_K)} : \Omega \rightarrow \mathbb{R}^{n_K}, \end{aligned}$$

где получаем множество отображений во множество локальных моделей, в которых учтены информации от каждого эксперта.

Также, как в и задаче одного эксперта вводится предположения, что каждая локальная модель является линейной:

$$\forall k \in \{1, \dots, K\}, \quad y \approx \mathbf{x}^T \mathbf{w}_k, \quad \forall (\mathbf{x}, y) \in \mathcal{D}(\Omega'_k, \mathbf{E}(\Omega_k)).$$

Заметим, что истинного разбиения Ω на множества $\{\Omega_k\}_{k=1}^K$ нету. Рассмотрим вектор функцию π :





$$\pi : \Omega \rightarrow \mathbb{R}^K, \quad \sum_{k=1}^K \pi_k(\omega) = 1, \quad \forall \omega \in \Omega,$$

где π назовем плюсовой функцией.

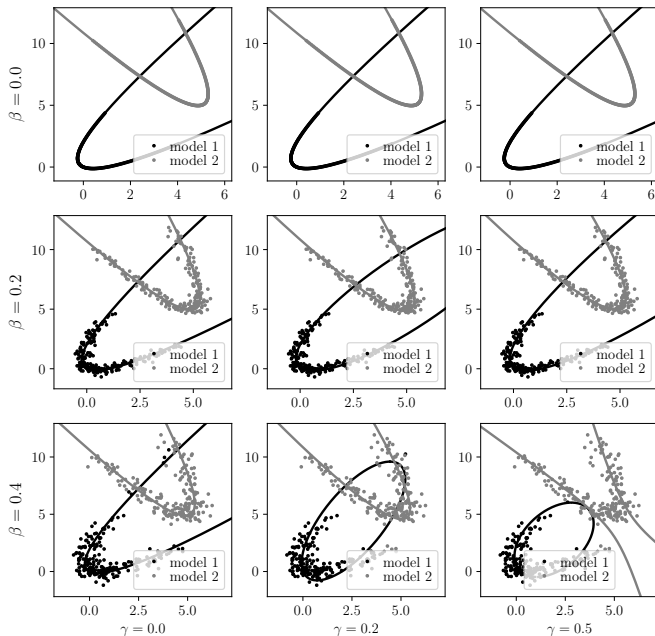
Предположим, что все $\left\{ \left(K_x^{E_k(\Omega_k)}, K_y^{E_k(\Omega_k)} \right) \right\}_{k=1}^K$ являются заданными отображениями. Используя локальные модели, построим глобальную мультимодель, которая описывает все множество объектов Ω :

$$\sum_{\omega \in \Omega'} \sum_{k=1}^K \pi_k(\omega, \mathbf{V}) \left(K_y^{E_k(\Omega_k)}(\omega) - \mathbf{w}_k^\top K_x^{E_k(\Omega_k)}(\omega) \right)^2 + R(\mathbf{V}, \mathbf{W}, \mathbf{E}(\Omega)) \rightarrow \min_{\mathbf{V}, \mathbf{W}}$$

где $\mathbf{W} = [\mathbf{w}_1^\top, \dots, \mathbf{w}_K^\top]$, а $R(\mathbf{V}, \mathbf{W}, \mathbf{E}(\Omega))$ является некоторой регуляризацией параметров, которая также основывается на экспертной информации, \mathbf{V} — параметры плюсовой функции.



Задача поиска кривых второго порядка: результат аппроксимации



Задача поиска кривых второго порядка: от уровня шума

